HỆ THỐNG TÍCH HỢP, PHÂN TÍCH HÀNH VI NGƯỜI DÙNG VÀ GỢI Ý MÓN ĂN

Đường ống dữ liệu lớn với Apache Spark, Kafka và Airflow trên bộ dữ liệu Food.com

Học phần: Tích hợp và phân tích dữ liệu lớn

Giảng viên hướng dẫn: ThS. Phạm Kim Thanh

Trường Công nghệ Thông tin Phenikaa – Đại học Phenikaa

Nhóm 12

Nguyễn Tuấn Anh (23010575) · Đinh Xuân Tài (23010616)

Hà Nội, tháng 10 năm 2026

Nội dung trình bày

1. Bài toán & dữ liệu

Mục tiêu, bộ dữ liệu Food.com, kiến trúc hệ thống

2. Tích hợp dữ liệu

Thu thập lô và luồng (Kafka), xử lý ELT, kho dữ liệu hình sao

3. Phân tích & gợi ý

Hành vi người dùng, phân cụm K-Means, 4 mô hình gợi ý

4. Triển khai & kết luận

Dashboard, API, Airflow; kết quả và hạn chế

Bài toán & mục tiêu

Bối cảnh

Nền tảng ẩm thực sinh ra hàng triệu lượt chấm điểm, nhận xét; người dùng **quá tải lựa chọn**, nền tảng cần **cá nhân hóa**. Dữ liệu phân tán, nhiều lỗi, rất thưa $\Rightarrow$ cần một **đường ống tích hợp dữ liệu**.

1. Tích hợp

Pipeline 6 bước theo Lecture 4, kết hợp lô và luồng, điều phối tự động

2. Phân tích hành vi

Người dùng chấm điểm thế nào, tập trung vào ai, có những nhóm nào?

3. Gợi ý món ăn

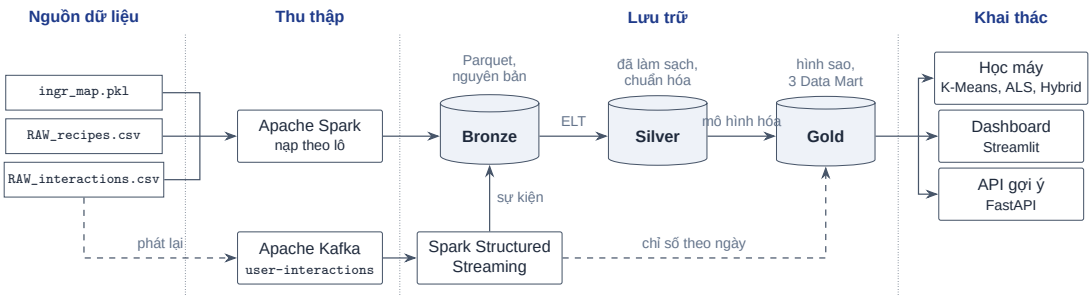
Top-10 món chưa tương tác cho mỗi người dùng; đo bằng HR@10, NDCG@10

Dữ liệu: Food.com Recipes and User Interactions (Kaggle)

231.637 công thức · **1.132.367** tương tác · **226.570** người dùng · 2000–2018 · 615 MB; đủ 3 dạng: có cấu trúc (điểm), bán cấu trúc (danh sách nguyên liệu), phi cấu trúc (nhận xét)

Kiến trúc hệ thống

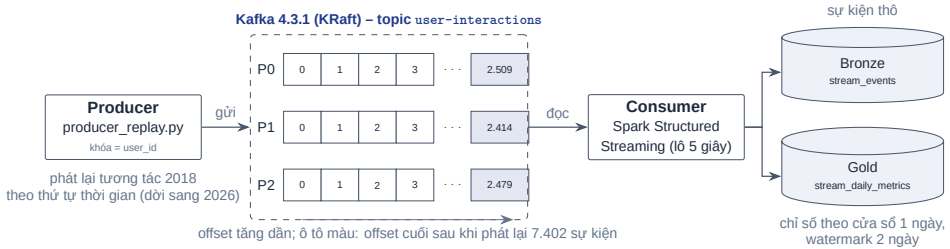
Pipeline Bronze – Silver – Gold, kết hợp xử lý lô và luồng



Môi trường: Linux 2 nhân, 7 GB RAM · Spark 4.0.1 · Kafka 4.3.1 · Airflow 3.1.7 · Streamlit · FastAPI · Python 3.13

Thu thập dữ liệu: lô và luồng

Luồng sự kiện qua Kafka (chạy thật)



Theo lô (Spark)

CSV → Parquet tầng Bronze: số dòng khớp 100%, ≈ 40 giây, dung lượng giảm 43–57%

Theo luồng (Kafka)

7.402 sự kiện, 545–1.041 sự kiện/giây, Bronze nhận đủ, khớp offset. Luồng là **mô phỏng** (`simulated=true`)

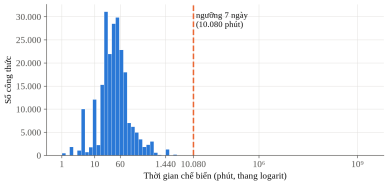
Xử lý ELT và chất lượng dữ liệu

Sáu thao tác biến đổi (tầng Silver)

Thao tác	Quy tắc	Bản ghi
Làm sạch	thời gian = 0 / > 7 ngày, calories > 10.000 → NULL + cờ	1.350 / 125
Kiểm tra		60.847
Ghép bảng	**rating = 0** là “không chấm” → NULL chỉ giữ tương tác có món hợp lệ	-3
Chuẩn hóa	tên nguyên liệu qua `ingr_map`	18.595 → 15.000
Tạo cột	7 cột dinh dưỡng, nhóm thời gian nấu, năm/tháng	toàn bộ

Nguyên tắc **gắn cờ thay vì xóa**: chỉ mất 2 công thức, 3 tương tác; mọi quy tắc ghi nhật ký.

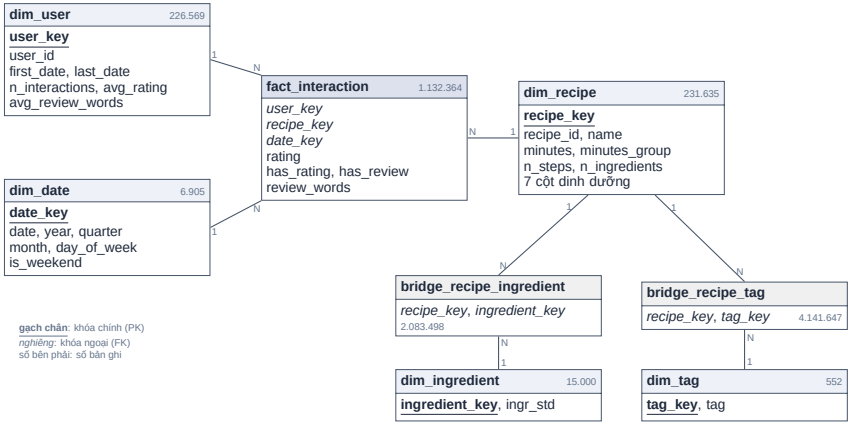
Lỗi phát hiện trong dữ liệu gốc



- Thời gian nấu **2.147.483.647 phút** (tràn số 32 bit)
- `ingr_map` của tác giả: **“flour” → “flmy”** (106 mục)

Kho dữ liệu hình sao (tầng Gold)

Lược đồ hình sao

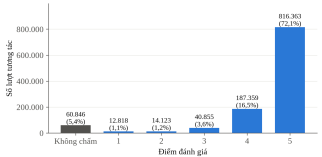


Thiết kế

- Hạt fact: 1 lượt tương tác
- 5 bảng chiều, 2 bảng cầu nối
- 3 Data Mart: hoạt động tháng, độ phổ biến (Bayes), đặc trưng người dùng
- Thô 615 MB → Gold **80 MB**

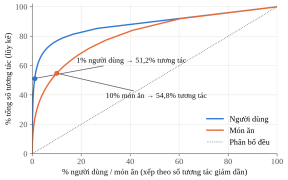
Phân tích hành vi người dùng

Điểm lệch về 5 sao



76,2% là 5 sao, TB 4,66 ⇒ dùng **phản hồi ngầm định**

Tương tác rất tập trung



1% người dùng tạo **51,2%** tương tác; **73,4%** chỉ tương tác 1 lần

Xu hướng theo thời gian



Đỉnh **01/2008**, giảm từ 2010; Chủ nhật, thứ Hai cao nhất

Phân nhóm người dùng bằng K-Means (K = 4)

Bốn nhóm người dùng (6 đặc trưng hành vi)

Nhóm	%ND	%TT	Điểm
Tích cực	19,7	**82,1**	4,67
Vãng lai – món cầu kỳ	38,0	8,6	4,80
Vãng lai – món nhanh	35,3	7,7	4,80
Khó tính	7,1	1,6	**1,96**

K = 4: điểm gãy Elbow, Silhouette 0,23, dễ diễn giải.

Ý nghĩa cho bài toán gợi ý

- Dưới 20% người dùng tạo hơn 80% tương tác ⇒ mô hình học chủ yếu từ nhóm tích cực
- Hơn 70% là vãng lai ⇒ cần chiến lược riêng cho người dùng mới: món phổ biến theo sở thích nhóm (nhanh 30 phút / cầu kỳ 70 phút)

Mô hình gợi ý: thiết lập & kết quả

Tập train/test của Kaggle không dùng được

100% món trong test không có trong train $\Rightarrow$ tự chia lại: lọc người dùng, món $\geq$ 5 tương tác (17.816 người dùng, 41.253 món), tương tác cuối theo thời gian làm test.

Bốn mô hình

- **Popularity** – mốc so sánh
- **Content-based** – TF-IDF nguyên liệu + tag
- **ALS** – Spark MLlib, phản hồi ngầm định
- **Hybrid** – $0{,}8 \cdot \text{ALS} + 0{,}2 \cdot \text{CB}$ (chuẩn hóa z-score)

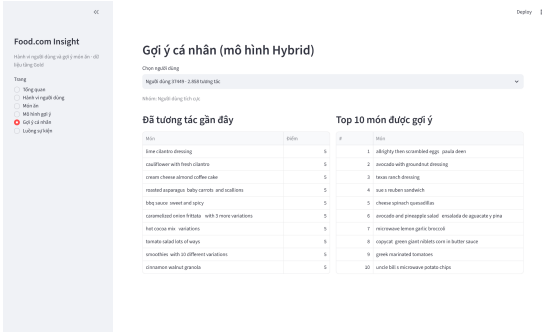
Kết quả trên tập kiểm thử (K = 10)

Mô hình	HR@10	NDCG@10	Độ phủ
Popularity	0,0228	0,0108	0,1%
Content-based	0,0021	0,0010	57,4%
ALS	0,0236	0,0120	4,5%
Hybrid	**0,0244**	**0,0123**	4,8%

- Hybrid tốt nhất: NDCG **+13,6%**, độ phủ **×36** so với Popularity
- Ngẫu nhiên chỉ đạt HR@10 $\approx$ 0,00024 (tìm 1 món trong 41 nghìn món) $\Rightarrow$ Hybrid tốt hơn $\approx$ 100 lần

Triển khai: Dashboard & API gợi ý

Dashboard Streamlit (6 trang, đọc tầng Gold)



Trang Gợi ý cá nhân: chọn người dùng → lịch sử + 10 món gợi ý (Hybrid)

API FastAPI `GET /recommend/{user_id}`

Tự chọn chiến lược theo người dùng:

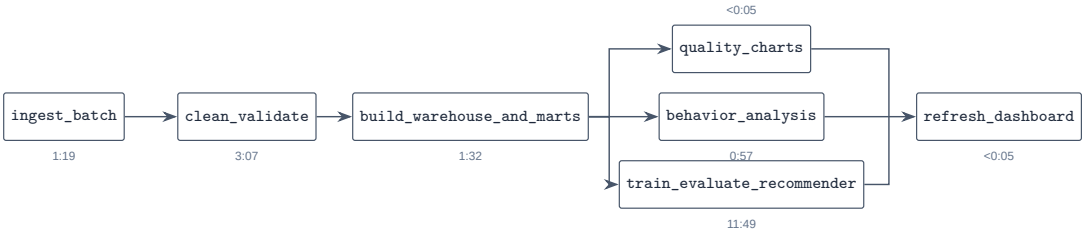
1. **hybrid**: có gợi ý cá nhân
2. **popularity_segment**: đã thuộc nhóm K-Means
3. **popularity**: người dùng hoàn toàn mới

Demo

```
streamlit run src/app_streamlit.py
python src/api_recommend.py → /docs
```

Điều phối bằng Apache Airflow

DAG `foodcom_pipeline` – lượt chạy theo lịch 18/10/2026: 7/7 tác vụ thành công, 19 phút 02 giây



Lịch: `0 2 * * *` (2:00 hằng ngày) retries = 2 số dưới mỗi tác vụ: thời gian chạy (phút:giây), lượt 18/10/2026

Vai trò

Airflow chỉ sắp thứ tự, lập lịch và chạy lại khi lỗi; việc xử lý do các script Spark thực hiện.

Nhận xét

Huấn luyện và đánh giá mô hình chiếm **62%** thời gian (11 phút 49 giây).

Kết luận & Hướng phát triển

Kết quả đạt được

- Pipeline 6 bước chạy trên toàn bộ 1,13 triệu tương tác, kết hợp lô và luồng
- Phát hiện, sửa lỗi trong dữ liệu gốc; kho hình sao, Gold 80 MB
- 4 nhóm người dùng có ý nghĩa
- Hybrid tốt nhất: NDCG@10 = 0,0123
- Dashboard, API, DAG Airflow chạy thành công

Hạn chế

- Luồng sự kiện mô phỏng; Kafka 1 nút, chạy một máy
- Gợi ý cá nhân mới tính sẵn cho 300 người dùng

Hướng phát triển

- Nguồn sự kiện thật, cụm Spark / cloud
- Đặc trưng văn bản nhận xét, gợi ý tuần tự

Hỏi – Đáp & Tài liệu tham khảo

Tài liệu tham khảo chính

1. ThS. Phạm Kim Thanh. Bài giảng Tích hợp và phân tích dữ liệu lớn, Lecture 4: Pipeline dữ liệu. Đại học Phenikaa.
2. Majumder, B. P. et al. (2019). Generating Personalized Recipes from Historical User Preferences. *EMNLP-IJCNLP*.
3. Hu, Y., Koren, Y., Volinsky, C. (2008). Collaborative Filtering for Implicit Feedback Datasets. *IEEE ICDM*.
4. Kimball, R., Ross, M. (2013). *The Data Warehouse Toolkit*, 3rd ed. Wiley.

Thảo luận

CẢM ƠN THẦY VÀ CÁC BẠN!

Hỏi – Đáp & Thảo luận

github.com/NguyenTuanAnh-Hara/TH_PTDLL