K-Nearest Neighbors (KNN)

Thuật toán K láng giềng gần nhất
và ứng dụng phân loại hoa Iris

Học phần: Khai phá dữ liệu

Giảng viên hướng dẫn: TS. Trịnh Thành

Nguyễn Tuấn Anh – 23010575
Lê Anh Duy – 23010710
Đinh Xuân Tài – 23010616

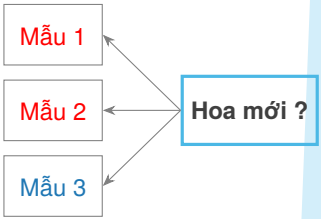
- Giới thiệu
- Một số công việc liên quan
- Thuật toán KNN
- Thực nghiệm và phân tích kết quả
- Kết luận

Giới thiệu

- Một số công việc liên quan
- Thuật toán KNN
- Thực nghiệm và phân tích kết quả
- Kết luận

Đặt vấn đề

- Bài toán: xác định loài của một bông hoa Iris mới – **Setosa**, **Versicolor** hay **Virginica**
- Cách tiếp cận của nhà thực vật học:
  - Đối chiếu với các mẫu đã biết loài có kích thước **tương đồng nhất**
  - Xem xét loài của các mẫu tương đồng đó
  - Kết luận theo **đa số**
- Hình thức hóa quá trình này thành thuật toán ⇒ **KNN**

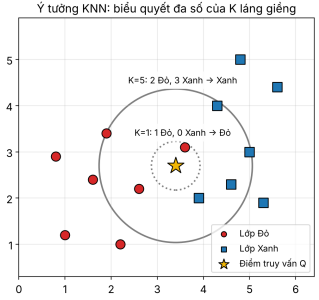


Học máy và bài toán phân lớp

- **Học máy (Machine Learning)**: máy tính tự rút ra quy luật từ dữ liệu, thay vì được lập trình sẵn từng quy tắc.
- **Phân lớp (classification)**:
  - Cho các mẫu **đã biết nhãn** (dữ liệu huấn luyện)
  - Xây dựng mô hình để **dự đoán nhãn cho mẫu mới**
  - Ví dụ: phân loại thư rác; chẩn đoán khối u lành tính / ác tính
- Các thuật toán phân lớp: Cây quyết định, Naive Bayes, SVM, Hồi quy Logistic, **KNN**…
- KNN là thuật toán **đơn giản và trực quan nhất**.

KNN là gì?

- KNN = **K láng giềng gần nhất**
- Giả định **tương đồng cục bộ**: các điểm gần nhau có xu hướng cùng nhãn
- Dự đoán nhãn của điểm mới:
  - Xác định **K láng giềng gần nhất**
  - Thực hiện **biểu quyết đa số**
  - Lớp có nhiều phiếu nhất là nhãn dự đoán
- Không xây dựng mô hình tường minh, chỉ lưu trữ dữ liệu
- Thực nghiệm: phân loại hoa Iris (Fisher, 1936)



- Giới thiệu
- Công việc liên quan
- Thuật toán KNN
- Thực nghiệm và phân tích kết quả
- Kết luận

Một số ứng dụng của KNN

- **Y tế**: hỗ trợ chẩn đoán dựa trên các ca bệnh tương đồng
- **Hệ thống khuyến nghị**: lọc cộng tác theo người dùng / sản phẩm tương đồng
- **Nhận dạng mẫu**: chữ viết tay, hình ảnh
- **Điền giá trị khuyết thiếu**: ước lượng từ K mẫu tương đồng (KNN Imputation)
- **Truy vấn tương đồng**: tìm kiếm văn bản, hình ảnh theo biểu diễn vector

Các công trình nghiên cứu liên quan

Năm	Tác giả	Đóng góp chính
1951	Fix & Hodges	Phân lớp phi tham số dựa trên láng giềng gần – tiền thân của KNN
1967	Cover & Hart	Sai số tiệm cận của 1-NN $\leq$ **2 lần** sai số Bayes
1976	Dudani	KNN có trọng số theo khoảng cách
1977	Friedman và cs.	Cấu trúc KD-Tree tăng tốc truy vấn láng giềng
1999	Beyer và cs.	Phân tích hiện tượng "lời nguyền số chiều"
2008	Wu và cs.	KNN thuộc **Top 10 thuật toán khai phá dữ liệu**

- Giới thiệu
- Một số công việc liên quan
- Thuật toán KNN
- Thực nghiệm và phân tích kết quả
- Kết luận

Ý tưởng và bản chất

- Giả định **tương đồng cục bộ**: các điểm gần nhau trong không gian đặc trưng có xu hướng cùng nhãn
- Mỗi mẫu là một **điểm** trong không gian *d* chiều, mỗi đặc trưng là một **trục tọa độ**
- Ba tính chất:
  - **Học lười (lazy learning)**: huấn luyện chỉ lưu trữ dữ liệu, chi phí tính toán dồn vào giai đoạn dự đoán
  - **Phi tham số**: không giả định dạng hàm hay phân phối của dữ liệu
  - **Dựa trên độ đo khoảng cách**: phụ thuộc độ đo và thang đo của đặc trưng

Cơ sở xác suất của biểu quyết

- Tỉ lệ láng giềng thuộc lớp *c* là ước lượng của **xác suất hậu nghiệm**:

$$P(c \mid x) \approx \frac{k_c}{K}$$

(k_c: số láng giềng thuộc lớp *c*, K: tổng số láng giềng)

- Lớp có nhiều phiếu nhất $\equiv$ lớp có **xác suất hậu nghiệm lớn nhất**
- KNN xấp xỉ **bộ phân lớp Bayes** – bộ phân lớp có xác suất sai nhỏ nhất
- **Ví dụ** (thực nghiệm): $K = 19$, có 12 láng giềng Virginica
  - $P(\text{Virginica}) \approx 12/19 = 0{,}63 \quad \Rightarrow$ dự đoán **Virginica**

Ký hiệu và công thức

Ký hiệu	Ý nghĩa
n	số mẫu huấn luyện (120)
d	số đặc trưng (2)
x_i, y_i	đặc trưng, nhãn mẫu thứ i
x	điểm truy vấn
K	số láng giềng
$N_K(x)$	K điểm gần x nhất
$\hat{y}$	nhãn dự đoán

Phân lớp – biểu quyết đa số:

$$\hat{y} = \arg\max_{c} \sum_{x_i \in N_K(x)} \mathbb{I}(y_i = c)$$

$\mathbb{I}(y_i = c) = 1$ nếu láng giềng thuộc lớp c, ngược lại $= 0$

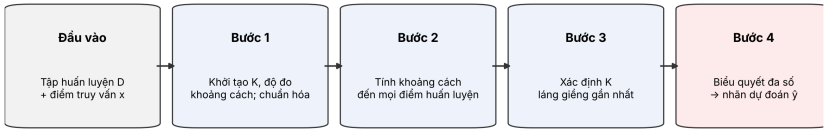
$\Rightarrow$ tổng Σ = **số phiếu** của lớp c

Hồi quy – lấy trung bình:

$$\hat{y} = \frac{1}{K} \sum_{x_i \in N_K(x)} y_i$$

Các bước của thuật toán

- Huấn luyện: **lưu trữ dữ liệu**. Với mỗi điểm truy vấn *x*, thực hiện 4 bước:



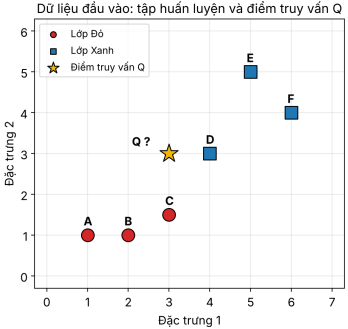
Khởi tạo tham số $\rightarrow$ Tính khoảng cách $\rightarrow$ Xác định K láng giềng $\rightarrow$ Biểu quyết đa số

Ví dụ minh họa

- Tập huấn luyện gồm 6 điểm:

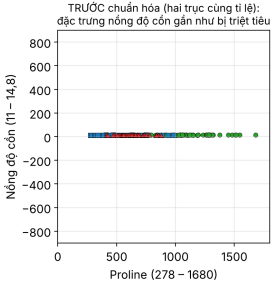
Điểm	Tọa độ	Lớp
A	(1; 1)	Đỏ
B	(2; 1)	Đỏ
C	(3; 1,5)	Đỏ
D	(4; 3)	Xanh
E	(5; 5)	Xanh
F	(6; 4)	Xanh

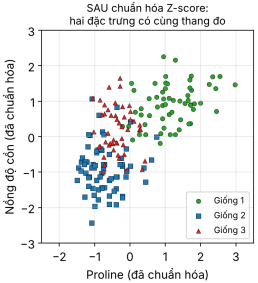
- Phân lớp điểm truy vấn **Q(3; 3)** với **K = 3**



Bước 1 -- Khởi tạo và tiền xử lý

- Khởi tạo **K = 3**, độ đo khoảng cách **Euclid**
- **Chuẩn hóa** đặc trưng về cùng thang đo (ví dụ có cùng miền giá trị nên không cần)
- Dữ liệu thực (Wine): proline (278 – 1680) chi phối nồng độ cồn (11 – 14,8)



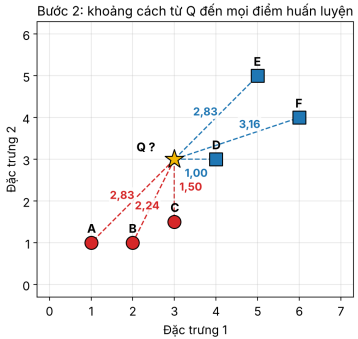


Bước 2 -- Tính khoảng cách

$d(Q,P) = \sqrt{(Q_1 - P_1)^2 + (Q_2 - P_2)^2}$

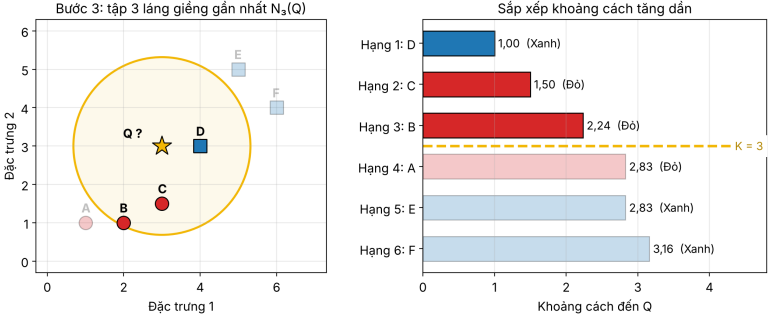
Điểm	Phép tính	d
A	$\sqrt{2^2 + 2^2} = \sqrt{8}$	2,83
B	$\sqrt{1^2 + 2^2} = \sqrt{5}$	2,24
C	$\sqrt{0^2 + 1{,}5^2}$	1,50
D	$\sqrt{1^2 + 0^2} = \sqrt{1}$	**1,00**
E	$\sqrt{2^2 + 2^2} = \sqrt{8}$	2,83
F	$\sqrt{3^2 + 1^2} = \sqrt{10}$	3,16

Tính với **toàn bộ** *n* điểm ⇒ chi phí lớn nhất



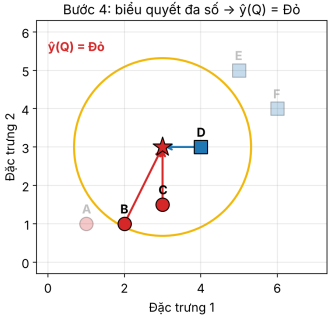
Bước 3 -- Xác định K láng giềng

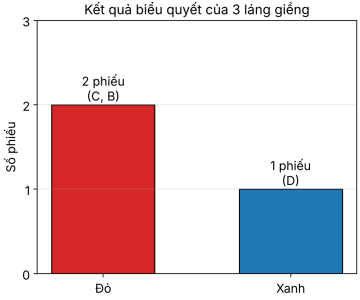
- Sắp xếp tăng dần: D (1,00) → C (1,50) → B (2,24) → A, E (2,83) → F (3,16)
- K = 3 $\Rightarrow N_3(Q) = \{$**D, C, B**$\}$



Bước 4 -- Biểu quyết đa số

- Lớp Đỏ: C, B – **2 phiếu** Lớp Xanh: D – **1 phiếu** $\Rightarrow \hat{y}(Q)$ **= Đỏ**
- Láng giềng gần nhất thuộc lớp Xanh, nhưng lớp Đỏ chiếm **đa số trong vùng lân cận**





Mã giả thuật toán KNN

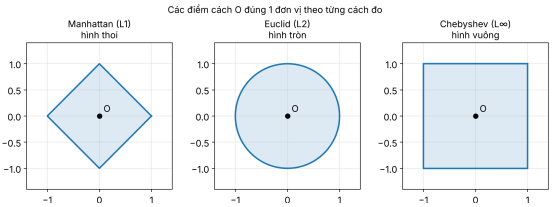
```
Input: D          // tập huấn luyện {(x_i, y_i)}
       x          // điểm truy vấn
       K          // số láng giềng
Output: ŷ         // nhãn dự đoán

L = ∅
for each (x_i, y_i) in D do
   L = L ∪ { (d(x, x_i), y_i) }    // Bước 2: tính khoảng cách
sắp xếp L tăng dần theo khoảng cách  // Bước 3: xác định láng giềng
N = K phần tử đầu tiên của L
ŷ = nhãn xuất hiện nhiều nhất trong N // Bước 4: biểu quyết
return ŷ
```

Độ đo khoảng cách

Độ đo	Công thức	Đặc điểm
Euclid	$\sqrt{\sum_j (x_j - z_j)^2}$	Độ dài đoạn thẳng – **phổ biến nhất**
Manhattan	$\sum_j \lvert x_j - z_j \rvert$	Tổng độ lệch tuyệt đối theo từng trục
Chebyshev	$\max_j \lvert x_j - z_j \rvert$	Chỉ xét chiều có độ lệch lớn nhất
Cosine	$1 - \frac{x \cdot z}{\lVert x \rVert \, \lVert z \rVert}$	Đo độ lệch về hướng, không phụ thuộc độ lớn

- Ví dụ $x = (1; 2)$, $z = (4; 6)$: Euclid = 5, Manhattan = 7, Chebyshev = 4



Chuẩn hóa dữ liệu

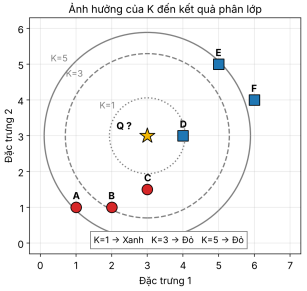
- Đặc trưng có **miền giá trị lớn chi phối khoảng cách**: thu nhập (100 – 1000) so với tuổi (18 – 60)

Min-Max: $x' = \frac{x - \min}{\max - \min}$ Z-score: $x' = \frac{x - \mu}{\sigma}$ (μ: trung bình, σ: độ lệch chuẩn)

- Ước lượng min, max, μ, σ **chỉ trên tập huấn luyện** (tránh rò rỉ dữ liệu)
- **Ví dụ** (tuổi; thu nhập triệu đồng): A = (25; 300) không mua, B = (44; 340) mua, Q = (43; 305)
  - Không chuẩn hóa: $d(Q, A) \approx 18{,}7$, $d(Q, B) \approx 35{,}0 \Rightarrow$ **không mua**
  - Chuẩn hóa Min-Max: $d(Q, A) \approx 0{,}429$, $d(Q, B) \approx 0{,}046 \Rightarrow$ **mua**
- Chuẩn hóa làm **đảo ngược kết quả** vì tuổi của Q gần như trùng với B

Lựa chọn tham số K

- **K nhỏ** (K = 1):
  - Phương sai cao, nhạy với nhiễu
  - **Quá khớp (overfitting)**
- **K lớn**:
  - Độ lệch cao, biên quyết định quá trơn
  - **Chưa khớp (underfitting)**
- Lựa chọn K bằng **kiểm định chéo**
- Bài toán hai lớp: chọn **K lẻ** để tránh hòa phiếu



Kiểm định chéo: ví dụ

- **Kiểm định chéo**: lần lượt dùng một phần dữ liệu làm tập đánh giá, phần còn lại làm dữ liệu tham chiếu, lấy trung bình độ chính xác
- Ví dụ: **Leave-One-Out** trên 6 điểm A–F

K	Độ chính xác	Giải thích
1	5/6	Phân lớp sai D do láng giềng gần nhất là C (Đỏ)
3	**6/6**	Cao nhất ⇒ **chọn K = 3**
5	0/6	Tập láng giềng là toàn bộ dữ liệu còn lại (chưa khớp)

KNN có trọng số, hồi quy

- **KNN có trọng số** (Dudani, 1976): trọng số **tỉ lệ nghịch với khoảng cách**

$$w_i = \frac{1}{d(x, x_i)}$$ lớp thắng = lớp có **tổng** *w* lớn nhất

- Ví dụ Q: Xanh = 1/1 = 1,00; Đỏ = 1/1,5 + 1/2,24 = 1,12 ⇒ vẫn **Đỏ**. Giảm phụ thuộc vào K, hạn chế hòa phiếu
- **KNN hồi quy**: dự đoán giá trị liên tục bằng **trung bình** của K láng giềng
  - Giá nhà 72 m², K = 3: nhà 60, 70, 80 m² giá 1,8; 2,1; 2,6 tỷ
  - $\hat{y} = (1{,}8 + 2{,}1 + 2{,}6)/3 \approx 2{,}17$ tỷ

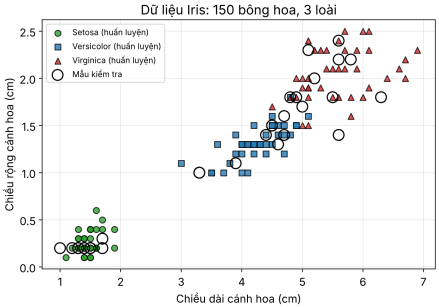
Một số vấn đề mở rộng

- **Tốc độ**
  - Huấn luyện $O(1)$; mỗi lần dự đoán có chi phí $O(n \cdot d)$
  - Tăng tốc: KD-Tree, tìm láng giềng gần xấp xỉ
- **Cơ sở lý thuyết** (Cover & Hart, 1967)
  - Khi $n \to \infty$: sai số của 1-NN $\leq$ **2 lần** sai số Bayes
- **Lời nguyền số chiều**
  - Số chiều lớn $\Rightarrow$ khoảng cách giữa các cặp điểm xấp xỉ nhau
  - Cần giảm chiều dữ liệu (ví dụ PCA)

- Giới thiệu
- Một số công việc liên quan
- Thuật toán KNN
- Thực nghiệm
- Kết luận

Dữ liệu Iris

- Bộ dữ liệu kinh điển (Fisher, 1936), có sẵn trong scikit-learn
- **150** bông hoa, **3** loài, mỗi loài 50 bông
- Sử dụng **2** đặc trưng: chiều dài và chiều rộng **cánh hoa** (cm)
- Setosa **tách biệt**; Versicolor và Virginica **chồng lấn một phần**
- Cùng đơn vị cm $\Rightarrow$ **không cần chuẩn hóa**



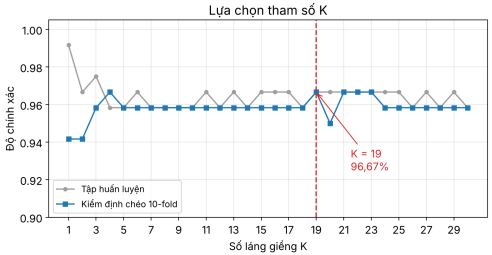
Phương pháp và cài đặt

1. Tập huấn luyện 80% (120 mẫu), tập kiểm tra 20% (30 mẫu), phân tầng theo loài
2. Lựa chọn K bằng **kiểm định chéo 10-fold** trên tập huấn luyện
3. Phân lớp 30 mẫu kiểm tra bằng KNN tự cài đặt
4. Đánh giá: **độ chính xác** và **ma trận nhầm lẫn**

```
def knn_predict(X_train, y_train, x, k):
  d = np.sqrt(((X_train - x)**2).sum(axis=1))   # Bước 2
  idx = np.argsort(d)[:k]                       # Bước 3
  return Counter(y_train[idx]).most_common(1)[0][0] # Bước 4
```

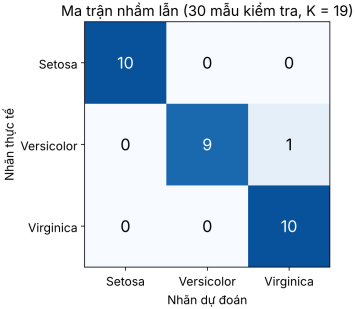
- Kiểm chứng: trùng khớp **30/30** dự đoán với KNeighborsClassifier (scikit-learn)

Lựa chọn tham số K



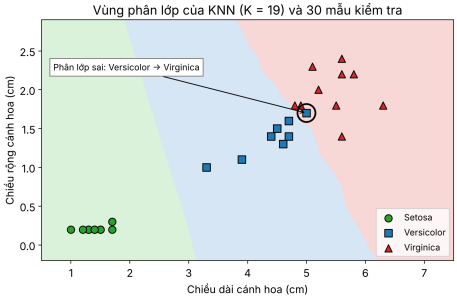
- **K = 1**: 99,17% trên tập huấn luyện, 94,17% kiểm định chéo ⇒ **quá khớp**
- K tăng: độ chính xác ổn định quanh 95,8% – 96,7%
- Lớp tách biệt tốt ⇒ ít nhạy với K
- Lựa chọn **K = 19** (96,67%)

Kết quả trên tập kiểm tra



- Phân lớp đúng **29/30** bông hoa
- Accuracy = **96,67%**
- Setosa: 10/10, Virginica: 10/10
- Versicolor: 9/10 – **1 bông bị nhầm thành Virginica**

Vùng phân lớp và phân tích sai số



- Mẫu sai: cánh hoa 5,0 cm × 1,7 cm, nằm tại **vùng chồng lấn** Versicolor – Virginica
- 19 láng giềng: **12 Virginica**, 7 Versicolor ⇒ biểu quyết ra Virginica
- Mẫu có số đo giống loài khác hơn loài của chính nó – giới hạn của dữ liệu, không phải lỗi cài đặt

Tổng hợp kết quả

Nội dung	Kết quả
Tham số K	K = 19 (kiểm định chéo 96,67%)
Độ chính xác trên tập kiểm tra	**96,67%** (29/30 mẫu)
Mẫu phân lớp sai	1 Versicolor → Virginica (vùng chồng lấn)
Kiểm chứng cài đặt	Trùng khớp 30/30 với scikit-learn

- KNN đạt độ chính xác cao với thuật toán đơn giản, không cần huấn luyện
- Sai số chỉ xuất hiện tại vùng chồng lấn giữa hai lớp

- Giới thiệu
- Một số công việc liên quan
- Thuật toán KNN
- Thực nghiệm và phân tích kết quả
- Kết luận

Kết luận

- **KNN**: phân lớp phi tham số dựa trên **tương đồng cục bộ** và **biểu quyết đa số**
- Phân loại hoa Iris: K = 19 $\Rightarrow$ Accuracy **96,67%** (29/30 mẫu)
- **Điểm mạnh**
  - Đơn giản, có khả năng diễn giải
  - Không cần huấn luyện; biểu diễn được biên quyết định phi tuyến
  - Dùng được cho phân lớp và hồi quy
- **Điểm yếu**
  - Chi phí dự đoán $O(n \cdot d)$ lớn khi dữ liệu lớn
  - Nhạy với thang đo, nhiễu; chịu ảnh hưởng của lời nguyền số chiều
  - Cần lựa chọn K; thiên về lớp đa số khi dữ liệu mất cân bằng

Tài liệu tham khảo

- Cover, T., Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Trans. Information Theory*.
- Dudani, S. A. (1976). The distance-weighted k-nearest-neighbor rule. *IEEE Trans. SMC*.
- Wu, X. et al. (2008). Top 10 algorithms in data mining. *Knowledge and Information Systems*.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*.
- Han, J., Kamber, M., Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- Trịnh Thành. *Bài giảng Khai phá dữ liệu*. Trường CNTT Phenikaa.

Cảm ơn thầy/cô và các bạn!

Hỏi – Đáp