THUẬT TOÁN K-NEAREST NEIGHBORS (KNN)

Lý thuyết và thực nghiệm chẩn đoán ung thư vú trên bộ dữ liệu Breast Cancer Wisconsin

Học phần: Khai phá dữ liệu

Giảng viên hướng dẫn: .....

Trường Công nghệ Thông tin Phenikaa – Đại học Phenikaa

Nhóm .....

Thành viên 1 (MSSV) · Thành viên 2 (MSSV)

Hà Nội, tháng 10 năm 2026

Nội dung trình bày

1. Giới thiệu & công việc liên quan

Bài toán phân lớp, ý tưởng KNN, ứng dụng và các bài báo liên quan

2. Thuật toán KNN

Các bước, ví dụ tính tay, chọn K, khoảng cách, chuẩn hóa, độ phức tạp

3. Thực nghiệm & phân tích

Dữ liệu ung thư vú, 8 thí nghiệm, so sánh với 4 thuật toán khác

4. Kết luận

Điểm mạnh, điểm yếu, hạn chế và hướng phát triển

Bài toán phân lớp & ý tưởng KNN

Bối cảnh

Phân lớp: dự đoán nhãn cho mẫu mới từ các mẫu đã biết nhãn (u **lành tính**/**ác tính**). KNN dựa trên ý tưởng **"những thứ giống nhau thì nằm gần nhau"**: tìm **K điểm gần nhất** rồi cho chúng **bỏ phiếu**.

1. Học lười (lazy)

Huấn luyện chỉ **lưu dữ liệu**, tính toán khi dự đoán

2. Phi tham số

Không giả định phân phối dữ liệu $\Rightarrow$ học được ranh giới **phi tuyến**

3. Dựa trên khoảng cách

Chất lượng phụ thuộc vào **K**, **độ đo khoảng cách** và **chuẩn hóa**

Mục tiêu bài tập lớn

Tự cài đặt KNN · thực nghiệm trên **Breast Cancer Wisconsin** · phân tích K, chuẩn hóa, độ đo · so sánh 4 thuật toán

Một số công việc liên quan

Các bài báo tiêu biểu

Năm	Tác giả	Đóng góp
1951	Fix & Hodges	Ý tưởng phân lớp phi tham số theo láng giềng
1967	Cover & Hart	Sai số 1-NN $\leq$ **2 lần** sai số Bayes
1968/72	Hart; Wilson	Condensed NN, Edited NN: giảm/làm sạch mẫu
1976	Dudani	KNN có **trọng số** theo khoảng cách
1977	Friedman và cs.	**KD-Tree** tìm láng giềng nhanh
1999	Beyer và cs.	**Lời nguyền số chiều**
1998/2018	Indyk; Malkov	LSH, HNSW: láng giềng gần **xấp xỉ**
2008	Wu và cs.	KNN thuộc **Top 10 thuật toán KPDL**

Ứng dụng

- Chẩn đoán y tế
- Hệ khuyến nghị (lọc cộng tác)
- Nhận dạng chữ viết tay (MNIST)
- Điền dữ liệu thiếu (KNN Imputer)
- SMOTE cho dữ liệu mất cân bằng
- Tìm kiếm vector, RAG

Thuật toán KNN: các bước

Bốn bước dự đoán cho một điểm mới x

Tập huấn luyện $D = \{(x_i, y_i)\}$ + điểm mới x → **B1.** Chọn K và hàm khoảng cách; chuẩn hóa dữ liệu → **B2.** Tính $d(x, x_i)$ với mọi $i = 1..n$ → **B3.** Sắp xếp, lấy K điểm gần nhất $N_K(x)$ → **B4.** Bỏ phiếu đa số (hồi quy: lấy trung bình)

Công thức dự đoán

Phân lớp: $\hat{y} = \arg\max_c \sum_{x_i \in N_K(x)} \mathbb{I}(y_i = c)$

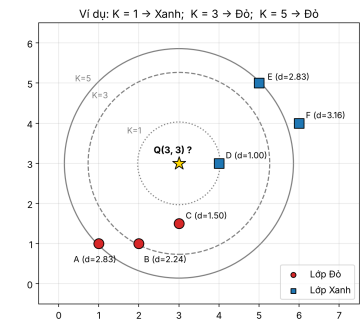
Hồi quy: $\hat{y} = \frac{1}{K} \sum_{x_i \in N_K(x)} y_i$

Có trọng số: $w_i = 1/d(x, x_i)$ (Dudani, 1976)

Độ đo khoảng cách thường dùng

Euclid	$\sqrt{\sum_j (x_j - z_j)^2}$
Manhattan	$\sum_j \lvert x_j - z_j \rvert$
Chebyshev	$\max_j \lvert x_j - z_j \rvert$
Cosine	$1 - (x \cdot z) \,/\, (\lVert x \rVert \, \lVert z \rVert)$

Ví dụ tính tay: phân lớp điểm $Q(3,3)$



B1. Khoảng cách Euclid, sắp xếp tăng dần

Điểm	Tọa độ	Lớp	$d(Q,\cdot)$
D	(4; 3)	Xanh	1,00
C	(3; 1,5)	Đỏ	1,50
B	(2; 1)	Đỏ	2,24
A, E	(1; 1), (5; 5)	Đỏ, Xanh	2,83
F	(6; 4)	Xanh	3,16

B2. Bỏ phiếu: kết quả phụ thuộc vào K

- K = 1 $\Rightarrow$ **Xanh** K = 3 (2 Đỏ, 1 Xanh) $\Rightarrow$ **Đỏ** K = 5 $\Rightarrow$ **Đỏ**
- Trọng số $1/d$, K = 3: Đỏ 1,12 $>$ Xanh 1,00 $\Rightarrow$ **Đỏ**

Các yếu tố quyết định chất lượng KNN

Chọn K: đánh đổi bias – variance

	K nhỏ	K lớn
Ranh giới	gồ ghề	mượt
Hiện tượng	**overfitting**	**underfitting**
Cực đoan	K=1: train 100%	K=n: luôn đoán lớp đông

Chọn K bằng **kiểm định chéo**; bài toán 2 lớp nên chọn **K lẻ**

Chuẩn hóa dữ liệu là bắt buộc

mean area: 143 – 2501 vs *mean smoothness*: 0,05 – 0,16
$\Rightarrow$ không chuẩn hóa thì khoảng cách gần như chỉ do diện tích quyết định.
Z-score: $x' = (x - \mu)/\sigma$, **fit trên tập train**

Độ phức tạp

Huấn luyện $O(1)$ · Dự đoán $O(n \cdot d)$ mỗi điểm
Tăng tốc: KD-Tree, Ball Tree, LSH, HNSW

Cơ sở lý thuyết & giới hạn

Cover–Hart: $R^* \leq R_{1NN} \leq 2R^*$
Lời nguyền số chiều: d lớn $\Rightarrow$ "gần" mất ý nghĩa

Thực nghiệm: dữ liệu & quy trình

Breast Cancer Wisconsin (Diagnostic)

569 mẫu · **30** đặc trưng số (10 đặc điểm nhân tế bào × mean/SE/max)
212 ác tính (37,3%) · **357** lành tính (62,7%) · không thiếu dữ liệu
Chia **80/20** phân tầng: 455 train, 114 test

Môi trường

Python 3 · NumPy · pandas · scikit-learn · matplotlib

8 thí nghiệm (chọn tham số bằng 10-fold CV trên tập train)

TN1	KNN tự cài đặt so với scikit-learn
TN2	Ảnh hưởng của K (1 – 30)
TN3	Có / không chuẩn hóa Z-score
TN4	4 độ đo × bỏ phiếu đều / trọng số
TN5	Mô hình cuối: ma trận nhầm lẫn, P, R, F1
TN6	Ranh giới quyết định (PCA 2 chiều)
TN7	So sánh NB, Cây QĐ, LogReg, SVM
TN8	Thời gian dự đoán theo n

Lớp **ác tính** là lớp dương tính ⇒ quan tâm **Recall**

Cài đặt KNN từ đầu (TN1)

`KNNScratch` – đúng 4 bước của thuật toán

```
class KNNScratch:
    def __init__(self, k=5):
        self.k = k
    def fit(self, X, y):          # chỉ lưu dữ liệu
        self.X, self.y = np.asarray(X), np.asarray(y)
        return self
    def _predict_one(self, x):
        d = np.sqrt(((self.X - x) ** 2).sum(axis=1))
        idx = np.argsort(d)[: self.k]
        return Counter(self.y[idx]).most_common(1)[0][0]
```

Kết quả kiểm chứng (K = 5)

Trùng khớp **114/114** dự đoán với `KNeighborsClassifier` của scikit-learn

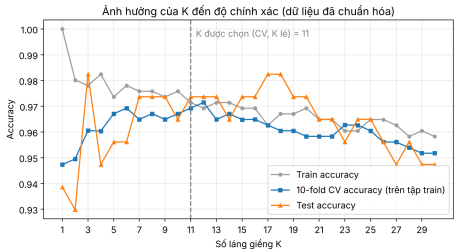
Cùng accuracy **95,61%** trên tập test

Pipeline chuẩn

`StandardScaler` → `KNN` đặt trong `cross_val_score` để chuẩn hóa được fit lại trên từng fold, **tránh rò rỉ dữ liệu**

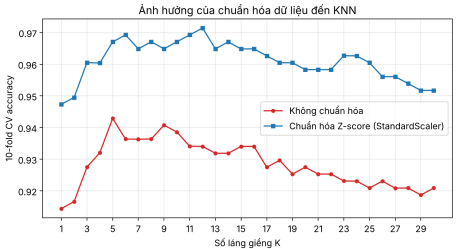
Kết quả: chọn K và vai trò của chuẩn hóa (TN2, TN3)

Accuracy theo K



K=1: train **100%**, test 93,86% (overfit) · Chọn **K = 11**: CV 96,93%, test **97,37%**

Có và không chuẩn hóa



Chuẩn hóa tốt hơn ***ở mọi K***; test (K=11): 93,86% → **97,37%** (7 → 3 mẫu sai)

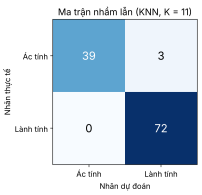
Kết quả: độ đo khoảng cách & mô hình cuối (TN4, TN5)

Độ đo × cách bỏ phiếu (K = 11)

Độ đo	Bỏ phiếu đều CV	Bỏ phiếu đều Test	Trọng số 1/d CV	Trọng số 1/d Test
Euclid	**96,93**	**97,37**	96,93	97,37
Manhattan	96,71	97,37	96,71	97,37
Chebyshev	**93,61**	92,98	93,61	92,98
Cosine	96,71	93,86	96,71	92,98

Chebyshev chỉ dùng 1 chiều; Cosine bỏ qua **độ lớn** khối u. Trọng số gần như không đổi kết quả.

Mô hình cuối: Z-score + KNN (K = 11, Euclid)



Accuracy **97,37%** (111/114)

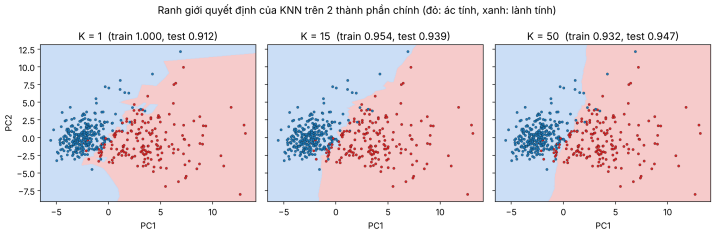
Ác tính: Precision **100%**, Recall **92,86%**, F1 96,30%

0 dương tính giả, **3** âm tính giả

Bỏ sót ca ác tính là lỗi nguy hiểm ⇒ cải thiện bằng hạ ngưỡng phiếu hoặc SMOTE

Ranh giới quyết định (TN6)

KNN trên 2 thành phần chính (PCA giữ 63,4% phương sai) – đỏ: ác tính, xanh: lành tính



K = 1

Gồ ghề, "ốc đảo" quanh nhiễu; train **100%**, test 91,2%

K = 15

Mượt hơn, hết ốc đảo; train 95,4%, test 93,9%

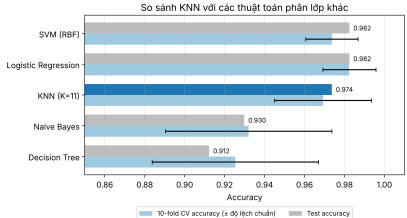
K = 50

Gần như đường cong trơn; train 93,2%, test 94,7%

So sánh KNN với các thuật toán khác (TN7)

Kết quả (%) – cùng chuẩn hóa, cùng cách chia dữ liệu

Thuật toán	CV	Test	F1 ác tính	Dự đoán
Logistic Regression	98,24	**98,25**	97,62	0,3 ms
SVM (RBF)	97,37	**98,25**	97,62	0,9 ms
KNN (K = 11)	96,93	**97,37**	96,30	**1,1 ms**
Naive Bayes	93,20	92,98	90,48	0,3 ms
Decision Tree	92,53	91,23	88,64	0,3 ms

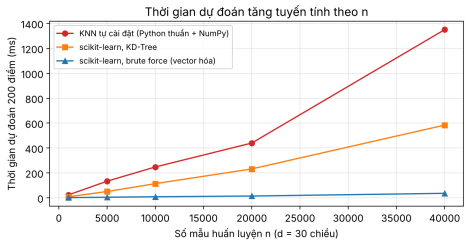


Nhận xét

- KNN **xếp thứ 3/5**, chỉ kém LogReg và SVM **1 mẫu** trên tập test
- Hơn rõ Naive Bayes (đặc trưng tương quan mạnh) và cây quyết định (dễ overfit)
- Hai lớp gần tách tuyến tính $\Rightarrow$ mô hình tuyến tính có lợi thế
- KNN huấn luyện tức thời nhưng **dự đoán chậm nhất**

Thời gian dự đoán & tổng hợp kết quả (TN8)

Thời gian dự đoán 200 điểm theo *n* (d = 30)



Tăng **tuyến tính** theo *n*; **KD-Tree chậm hơn** duyệt toàn bộ ở 30 chiều (lời nguyền số chiều)

Tổng hợp

TN1	Tự cài đặt khớp 100%
TN2	K = 11 tốt nhất (CV 96,93%)
TN3	Chuẩn hóa: +3,5 điểm % test
TN4	Euclid $\approx$ Manhattan $>$ Cosine $>$ Chebyshev
TN5	Acc 97,37%, Recall ác tính 92,86%
TN6	K điều khiển độ mượt ranh giới
TN7	Hạng 3/5 thuật toán
TN8	Dự đoán chậm khi *n* lớn

Kết luận & Hướng phát triển

Điểm mạnh

- Đơn giản, trực quan, dễ giải thích
- Không cần huấn luyện, thêm dữ liệu dễ dàng
- Học được ranh giới phi tuyến
- Phân lớp, hồi quy, nhiều lớp; lý thuyết vững

Điểm yếu

- Dự đoán chậm, tốn bộ nhớ khi n lớn
- Nhạy với thang đo, nhiễu, đặc trưng thừa
- Kém ở dữ liệu nhiều chiều
- Phải chọn K, độ đo; thiên vị lớp đông

Kết quả đạt được

Trình bày đầy đủ lý thuyết + ví dụ; tự cài đặt KNN; 8 thí nghiệm; accuracy **97,37%** trên dữ liệu ung thư vú

Hướng phát triển

Dữ liệu lớn hơn (MNIST) + PCA · SMOTE / hạ ngưỡng để tăng Recall · học độ đo (LMNN) · FAISS, HNSW

Hỏi – Đáp & Tài liệu tham khảo

Tài liệu tham khảo chính

1. Cover, T., Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Trans. Information Theory*.
2. Dudani, S. A. (1976). The distance-weighted k-nearest-neighbor rule. *IEEE Trans. SMC*.
3. Wu, X. et al. (2008). Top 10 algorithms in data mining. *Knowledge and Information Systems*.
4. Street, W. N., Wolberg, W. H., Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *SPIE*.
5. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*.

Thảo luận

CẢM ƠN THẦY/CÔ VÀ CÁC BẠN!

Hỏi – Đáp & Thảo luận